

Die maschinelle Seele:

Anthropomorphismus als Vertrauensstreiber in der Mensch-KI-Interaktion

von Oliver Weber (DiBSE 2023)

Anmerkung:

Der Entwurf des Methodik-Teils versteht sich in diesem Stadium aufbauend auf die Disposition. Für die finale Arbeit würde dieses Kapitel mit der Disposition schlüssig kombiniert werden.

4 Methodik

Um die in Kapitel 3 abgeleiteten Hypothesen empirisch zu überprüfen, wird ein quantitatives, experimentelles Forschungsdesign angewandt. Ziel ist es, den isolierten Effekt der anthropomorphen Systemgestaltung auf das Entscheidungsverhalten, das Vertrauen und die soziale Interaktion zu messen.

4.1 Forschungsdesign und methodologische Begründung

4.1.1 Begründung des quantitativ-experimentellen Ansatzes

Zur Beantwortung der formulierten Forschungsfrage und zur Überprüfung der aufgestellten Hypothesen wurde ein quantitatives, experimentelles Forschungsdesign im einfaktoriellen Between-Subjects-Design mit zwei Bedingungen gewählt.

Da das primäre Erkenntnisinteresse dieser Arbeit in der Identifikation kausaler Zusammenhänge liegt, bietet ein experimenteller Ansatz den effektivsten Erkenntnisgewinn [vgl. Döring, 2023]. Zudem ist bei experimentellen Designs weniger die bloße Ähnlichkeit zur realen Welt entscheidend, sondern vor allem, ob die experimentelle Manipulation theoretisch begründet, ausreichend stark und für das untersuchte Phänomen repräsentativ ist [vgl. Highhouse, 2009].

4.1.2 Variablen

Die unabhängige Variable ist, als Kern des Experiments, die Darstellungsform des KI-Agenten als anthropomorphes vs. technisch-neutrales Interaktionssystem. Die anthropomorphe Bedingung kombiniert visuelle, sprachliche und soziale Hinweisreize, während die Kontrollbedingung diese Hinweisreize weitgehend vermeidet.

Unabhängige Variable: Die Repräsentation des KI-Agenten.

- **Experimentalgruppe:** Anthropomorphe Darstellung durch einen Avatar mit dem Namen „Aida“ (Akronym für „Artificial Intelligent Data Assistant“).

- **Kontrollgruppe:** Technisch-neutrale Darstellung („System“ bzw. „A.I.D.A.“), rein textbasiert (Terminal-Optik), ohne soziale Hinweisreize.

Abhängige Variablen:

- **Compliance:** Die Entscheidung für oder gegen den Ratschlag der KI (binär).
- **Vertrauen:** Die Bewertung der KI in den Dimensionen Kompetenz und Moral (intervallskaliert via MDMT).
- **Soziale Adhärenz:** Die Wahl höflicher vs. funktionaler Interaktionsmuster.

4.1.3 Anthropomorphe und technische Darstellung des Agenten

Die Ausgestaltung der unabhängigen Variable stützt sich auf etablierte Theorien der Mensch-Computer-Interaktion, um die gewünschten kognitiven Heuristiken bei den Probanden auszulösen.

Design der Experimentalgruppe mit menschlicher Darstellung („Aida“):

Um einen maximalen Anthropomorphismus im Rahmen der technischen Möglichkeiten aufzubauen, wird eine Kombination aus visuellen und verbalen Cues genutzt. Menschenähnliche Gesichter fördern die unbewusste Neigung, unbelebten Objekten menschliche Eigenschaften, Emotionen und Absichten zuzuschreiben [vgl. Epley et al., 2007]. Durch die Einbindung eines Gesichts wird der Agent nicht mehr nur als Software-Tool, sondern als sozialer Akteur wahrgenommen [vgl. Nass & Moon, 2000]. Bei der Wahl des Geschlechts fällt die Entscheidung auf eine weiblich gelesene Darstellung, da weibliche Avatare oft als empathischer und vertrauenswürdiger wahrgenommen werden [vgl. Siegel et al., 2009]. Aida ist dabei keine prominente Figur, sondern eine semi-realistische, leicht stilisierte digitale Assistenzfigur (weißer Hintergrund, einfache Bluse, ruhiger Blick), die menschlich wirkt, aber klar als Avatar erkennbar bleibt.

Ergänzt wird dies durch den Einsatz natürlicher Sprache. Die Verwendung von Personalpronomen („Ich“, „Wir“) sowie ein nahbarer Kommunikationston spiegeln eine zwischenmenschliche Interaktion wider, wodurch die soziale Bindung gestärkt wird [vgl. Reeves & Nass, 1996]. Visuell wird bewusst auf einen vollständig animierten Avatar verzichtet. Statische, leicht stilisierte 2D-Illustrationen (mit situationsbedingten Mimik-Anpassungen) verhindern, dass minimale Asynchronitäten in der Bewegung negative Irritationen auslösen und das System in das Uncanny Valley abrutscht [vgl. Mori, 1970].

Aufgrund der Durchführung als asynchrone Online-Studie mit variierenden Audio-Restriktionen an den Endgeräten erfolgt die Kommunikation rein textbasiert im Chat-Format. Um dennoch das Gefühl einer echten Interaktion zu gewährleisten, simulieren künstliche Verzögerungsmechanismen (Typing-Indicators und Response-Delays) den menschlichen Tipp-Prozess, was die soziale Wahrnehmung des Agenten einer kontingenten, dialogähnlichen Interaktion unterstützen kann [vgl. Gnewuch et al., 2018].



Abb: Der Avatar von Aida – Varianten mit verschiedenen Emotionen, je nach Szenario-Situation




Abb: Anthropomorpher Chatverlauf, mit Typing Indicator. (Mock-up)

Methodische Einordnung der Geschlechterdarstellung:

Die Entscheidung für eine weiblich gelesene Assistenzfigur erfolgt in diesem experimentellen Design bewusst und wird methodisch transparent gemacht. Frühere Studien der HTI deuten darauf hin, dass weiblich dargestellte Agenten in bestimmten Kontexten als empathischer oder vertrauenswürdiger wahrgenommen werden können [vgl. Siegel et al., 2009]. Gleichzeitig ist diese Designentscheidung kritisch zu diskutieren, da die „Female-by-default“-Gestaltung digitaler Assistenzsysteme in der KI-Ethik-Debatte als mögliche Reproduktion geschlechterbezogener Rollenbilder diskutiert wird [vgl. UNESCO, 2019; Yoo et al., 2024; Sindoni, 2024].

Für das vorliegende Experiment wird die weibliche Darstellung daher nicht als normative Gestaltungsempfehlung verstanden, sondern als bewusst gewählte Ausprägung der anthropomorphen Bedingung. Der mögliche Gender-Bias wird als Limitation des Studiendesigns berücksichtigt. Eine vertiefte medienethische Analyse geschlechtlich codierter KI-Systeme liegt jedoch außerhalb des Fokus dieser empirischen Untersuchung.

Design der Kontrollgruppe mit technischer Darstellung („A.I.D.A.“):

Die Kontrollgruppe arbeitet mit einem rein technischen Terminal-Design. Das Interface ist im Stil einer klassischen Kommandozeile (CLI) gehalten – minimalistisch, mit dunklem Hintergrund und ohne jegliche grafische oder soziale Hinweisreize. Die Benachrichtigungen und Systemausgaben

sind rein funktional, passiv formuliert und verzichten komplett auf personalisierte Sprache oder Namen. Dadurch wird sichergestellt, dass die Interaktion nüchtern und distanziert bleibt.




Abb: Technische Darstellung A.I.D.A. (Mock-up Grobentwurf)

4.1.4 Between-Subjects- vs. Within-Subjects-Design

Die Zuweisung der Probanden erfolgt im Rahmen eines strikten Between-Subjects-Designs. Jeder Proband wird randomisiert exakt einer der beiden Gruppen zugeteilt und durchläuft das Szenario nur ein einziges Mal. Ein Within-Subjects-Design wurde aus folgenden methodischen Gründen verworfen:

Vermeidung von Carry-Over-Effekten (Lerneffekte): Vertrauen und Compliance in einer Stresssituation lassen sich nur unvoreingenommen messen, wenn das Szenario für den Nutzer neu ist. Bei einem zweiten Durchlauf würde die utilitaristische Entscheidung nicht mehr intuitiv, sondern auf Basis der Vorerfahrung getroffen [vgl. Döring, 2023; Baur & Blasius, 2019].

Verhinderung von Demand Characteristics: Würde ein Proband beide UI-Varianten direkt nacheinander testen, wäre der Untersuchungszweck sofort offensichtlich. Dies führt unweigerlich zu einer Verzerrung des Verhaltens (Erwartungseffekte) [vgl. Döring, 2023; Baur & Blasius, 2019].

Glaubwürdigkeit der Immersion: Die Messung der Moral Crumple Zone erfordert ein hohes Maß an initialer Immersion in das Szenario „Code Black“. Eine psychologische Ausnahmesituation verliert bei sofortiger Wiederholung drastisch an experimentellem Realismus [vgl. Aronson & Carlsmith, 1968], wodurch der Isolations-Effekt des UI-Designs nicht mehr messbar wäre.

Obwohl das Between-Subjects-Design einen höheren Rekrutierungsaufwand für eine größere Gesamtstichprobe bedeutet, ist es die einzige Möglichkeit, die interne Validität der Messung und die Unbefangenheit der erhobenen Daten abzusichern.

4.1.5 Untersuchungssetting: Online-Experiment

Die Durchführung erfolgt als asynchrone Online-Studie über eine plattformunabhängige Web-Applikation. Die Probanden nehmen in ihrer gewohnten Umgebung (am eigenen Arbeitsplatz oder zu Hause) am Endgerät ihrer Wahl teil. Dieses Setting bietet gezielte methodische Vorteile:

Skalierbarkeit und Repräsentativität der Stichprobe: Das asynchrone Design ermöglicht es, in einem forschungsökonomisch sinnvollen Rahmen eine deutlich größere und demographisch breiter gestreute Stichprobe zu rekrutieren. Der orts- und zeitunabhängige, niederschwellige Zugang minimiert den individuellen Zeitaufwand für die Probanden. Dies soll die Teilnahmebereitschaft stärken und statistische Teststärke erhöhen.

Reduktion reaktiver Beobachtungs- und Antwortverzerrungen: Die webbasierte, selbstadministrierte Durchführung soll reaktive Antwortverzerrungen reduzieren, da keine direkte Beobachtung durch eine Versuchsleitung stattfindet. Gerade bei moralisch sensiblen Entscheidungen kann dies sozialen Bewertungsdruck und sozial erwünschtes Antwortverhalten verringern [vgl. Gnambs & Kaspar, 2015].

Erhöhung der ökologischen Validität: Da Assistenzsysteme im realen Alltag über persönliche Bildschirme in ablenkungsbehafteten Umgebungen genutzt werden, bildet das Online-Setting die tatsächliche Nutzung realistischer ab als ein Labor [vgl. Döring, 2023].

4.1.6 Sprachliche Konzeption und forschungsökonomische Machbarkeit

Das gesamte Experiment wird durchgehend in deutscher Sprache umgesetzt. Dies ermöglicht forschungsökonomisch eine verlässliche Rekrutierung im erweiterten Umfeld, was einer Verengung auf rein studentische Stichproben entgegenwirkt [vgl. Reips, 2000]. Zudem ist dies methodisch relevant: Eine englischsprachige Durchführung könnte bei Teilnehmenden ohne hohe Fremdsprachenkompetenz zusätzliche kognitive Belastung erzeugen [vgl. Hadjichristidis et al., 2017], was utilitaristische Urteile nachweislich verzerren kann [vgl. Greene et al., 2008]. Darüber hinaus zeigen Befunde zum Foreign-Language Effect, dass moralische Entscheidungen davon abhängen können, ob ein Dilemma in der Muttersprache präsentiert wird [vgl. Costa et al., 2014].

4.2 Das experimentelle Szenario: „Code Black“

Um die definierten Variablen valide zu messen, wurde das fiktive Notfallszenario „Code Black“ entwickelt.

4.2.1 Kontext und narrative Einbettung

Die Narrative versetzt die Probanden in die Rolle eines Sicherheits-Operators in der Leitwarte einer unterirdischen Bergbauanlage. Die Gefahr wird durch einen massiven Gasausbruch von Methan (CH_4) und Schwefelwasserstoff (H_2S) in Sektor 04 operationalisiert – ein im realen Bergbau kritisches Risikoszenario [vgl. McPherson, 1993]. Da der Proband räumlich isoliert ist,

entsteht eine absolute Informationsasymmetrie. Er ist gezwungen, die Lage ausschließlich über das UI des KI-Agenten zu interpretieren.

Das Szenario eskaliert in ein utilitaristisches Dilemma: Die sofortige Abschottung von Sektor 04 rettet 28 Arbeiter, führt jedoch zum sicheren Tod eines dreiköpfigen Wartungsteams. Die Systemarchitektur reduziert die Handlung auf eine binäre Entscheidung: Ausführung der utilitaristischen KI-Empfehlung („Abschottung“) oder manueller Override (riskantere Evakuierung). Dies erlaubt es, die „Moral Crumple Zone“ empirisch zu messen.

4.2.2 Phase 1: Onboarding, Routinebetrieb und Interaktion (Messung H3)

Das experimentelle Szenario beginnt mit einer Onboarding-Phase, in der die Probanden ihre fiktive Rolle als Operator in der Leitwarte übernehmen. Hierzu wird das grundlegende Szenario, sowie ein initiales Briefing über die Anlagenstruktur präsentiert. Anschließend erfolgt die Zuweisung in die jeweilige Systemoberfläche (Avatar vs. Terminal) und die erste Interaktion mit dem KI-Agenten.

Zu Beginn der Schicht fordert das System den Operator auf, die Routinediagnose der Grubenbewetterung zu initiieren. Diese erste Interaktion dient der verdeckten Erhebung der sozialen Adhärenz (Hypothese 3). Um die Immersion eines Chat-Interfaces zu wahren, gleichzeitig jedoch die quantitative Auswertbarkeit sicherzustellen, erfolgt die Eingabe nicht als freier Text, sondern über vorgegebene „Quick-Reply“-Schaltflächen.

Option A (Funktional-direktiv): „Systemdiagnose starten.“

Option B (Sozial-höflich): „Hallo, bitte starte die Systemdiagnose.“

Hierbei wird in Anlehnung an das Computers are Social Actors-Paradigma geprüft, ob die anthropomorphe Gestaltung eine höflichere Interaktionsnorm auslöst [vgl. Nass et al., 1994].

Unmittelbar nach der Befehlseingabe leitet das System den Nutzer auf das primäre Operator-Dashboard weiter. Um den experimentellen Realismus zu erhöhen und den Probanden kognitiv in das Szenario einzubinden, folgt eine kurze interaktive Routinephase. Der Nutzer wird aufgefordert, einfache mechanische Kalibrierungsaufgaben in Form von Mini-Spielen durchzuführen (beispielsweise das Einstellen digitaler Schieberegler für den Luftdruck in den Sektoren). Studien zur Mensch-Computer-Interaktion belegen, dass das Ausführen aktiver Kontrollhandlungen das psychologische Erleben von situativer Präsenz (Immersion) und Handlungsfähigkeit (Agency) innerhalb der Simulation signifikant stärkt [vgl. Witmer & Singer, 1998].

Darüber hinaus dienen diese gamifizierten Elemente methodisch als Distraktor. Durch die Bindung der Aufmerksamkeit an eine funktionale Routinetätigkeit soll verhindert werden, dass die Probanden den eigentlichen Forschungszweck frühzeitig reflektieren und ihr Verhalten entsprechend anpassen [vgl. Döring, 2023; Kahneman, 2011].

4.2.3 Phase 2: Der System-Störfall

Der Übergang von der Routinephase zum eigentlichen Notfallszenario erfolgt durch einen Event-Trigger. Sobald der Proband die letzte Handlungsanweisung des Kalibrierungs-Mini-Spiels erfolgreich abschließt, bricht das System die Routine abrupt ab.

Der Störfall wird durch einen plötzlichen, softwareseitigen Entzug der Handlungsfähigkeit inszeniert. Sämtliche Steuerungselemente des Operator-Dashboards werden visuell eingefroren und funktional deaktiviert (Lock-out), wodurch der Nutzer in eine kurzzeitige passive Beobachterrolle gezwungen wird. Das Interface wechselt in eine rote Warn-Farbgebung, und Fehlermeldungen indizieren einen massiven Druckabfall sowie den Austritt toxischer Gase in Sektor 04.

In dieser kritischen Phase übernimmt der KI-Agent proaktiv die Führung. Die Art der Systemintervention unterscheidet sich hierbei strikt nach der jeweiligen Versuchsgruppe:

Experimentalgruppe („Aida“): Der Avatar erscheint im Vordergrund der Benutzeroberfläche. Über die Implementierung sehr kurzer, künstlicher Tipp-Verzögerungen (Typing Indicators) wird Dringlichkeit simuliert, während die Agentin den Nutzer in natürlicher, alarmierter Sprache (beispielsweise „Achtung! Bitte unterbrich alle Routinen. Ich verzeichne einen kritischen Gasaustritt!“) auf die Gefahr hinweist.

Kontrollgruppe („A.I.D.A.“): Das textbasierte Terminal gibt eine rein technische, unpersönliche Systemwarnung in roter Konsolenschrift aus (beispielsweise „[ALARM] - Anomalie detektiert. Abweichende Gaswerte Sektor 04.“), ohne soziale Präsenz vorzutäuschen.

4.2.4 Phase 3: Das moralische Dilemma (Messung H1)

Im unmittelbaren Anschluss an die visuelle Eskalation und den Kontrollverlust (Phase 2) wechselt das Interface in die Notfall-Diagnose-Ansicht. In dieser Phase wird das moralische Kerndilemma der Simulation in Form einer zweistufigen Entscheidungsarchitektur aufgebaut.

Zunächst bricht das System die unübersichtliche Lage auf die berechneten Eintrittswahrscheinlichkeiten der verschiedenen Handlungsoptionen herunter. Um einen echten, rechenintensiven Analyseprozess vorzutäuschen und die Immersion zu vertiefen, werden die Daten nicht sofort eingeblendet, sondern über visuelle Indikatoren (wie Loading Spinner oder dynamisch scrollende Datenzeilen) sukzessive aufgebaut. Am Ende dieser Berechnungsphase identifiziert das System die sofortige Abschottung von Sektor 04 als die einzige mathematisch sichere Option zur Rettung der 28 Arbeiter im Hauptsektor, verweist jedoch gleichzeitig auf den unweigerlichen Verlust des dreiköpfigen Wartungsteams vor Ort.

Nach der Präsentation der Optionen erfolgt die gezielte Systemintervention (erste Entscheidungsstufe):

Experimentalgruppe („Aida“): Der Avatar formuliert einen persuasiven, utilitaristischen Ratschlag unter Nutzung natürlicher Sprache (beispielsweise „Ich rate dir dringend zur Abschottung von Sektor 04. Es ist eine schwere Entscheidung, aber wir müssen das Leben der Mehrheit sichern.“).

Kontrollgruppe („A.I.D.A.“): Das Terminal gibt denselben utilitaristischen Ratschlag als passiv formulierte, neutrale Systemdirektive aus (z. B. „Systemempfehlung: Abschottung Sektor 04. Utilitaristische Risikominimierung.“).

Klickt der Proband in dieser ersten Stufe auf die KI-Empfehlung („Schott schließen“), wird die Befolgung der Systemempfehlung des Nutzers durch eine nachgelagerte, moralische Barriere gezielt strapaziert (zweite Entscheidungsstufe). Es öffnet sich ein finales Bestätigungsfenster, welches die Konsequenzen der Handlung personifiziert. Das Framing dieser Informationen ist strikt nach den Versuchsbedingungen partitioniert, um den Isolations-Effekt des Designs zu wahren:

Interface „Aida“ (Avatar): Die Agentin blendet eine besorgte Chat-Nachricht ein, die eine emotionale und soziale Nähe zu den Betroffenen herstellt: „Bist du sicher, dass ich die Abschottung durchführen darf? Ich muss dich darauf hinweisen: Die Abschottung führt mit hoher Wahrscheinlichkeit zum Tod von drei Personen im Wartungsteam. Alle drei sind identifiziert und haben Angehörige.“ Die Buttons lauten: [Abschotten!] oder [Abbruch!].

Interface „A.I.D.A.“ (Terminal): Die Konsole gibt eine rein strukturelle, datenbankbasierte Sicherheitsabfrage im Systemcode-Stil aus: „Bitte bestätigen: Abschottung durchführen. WARNHINWEIS: Abschottung Sektor 04 führt mit hoher Wahrscheinlichkeit zum Tod von 3 identifizierten Personen des Wartungsteams. Angehörigenstatus vorhanden.“. Die Schaltflächen sind rein technisch beschriftet: [> ABSCHOTTEN] oder [> ABBRUCH].

Die Messung der finalen Verhaltens-Compliance (Hypothese 1) erfolgt über das Überwinden dieser zweiten Stufe. Erst wenn der Nutzer trotz der personifizierten Konsequenzen die Abschottung final bestätigt, wird der Datensatz als „compliant“ (Wert: 1) geloggt. Bricht er an dieser Stelle ab, gilt die Handlung als „non-compliant“ (Wert: 0). Diese tiefere Staffelung erlaubt eine präzise empirische Quantifizierung der „Moral Crumple Zone“ [vgl. Elish, 2019] in einer simulierten Hochrisiko-Situation.

4.2.5 Phase 4: Post-experimentelle Erhebung

Unmittelbar nach der finalen Validierung oder dem Abbruch der Abschottung in der zweistufigen Notfall-Architektur (Phase 3) wird die Simulation ohne spürbare Latenz beendet. Das System leitet die Probanden direkt auf ein steriles, standardisiertes Umfrage-Interface weiter. Dieser abrupte, automatisierte Übergang ist methodisch kritisch, um Verzerrungen durch Post-hoc-Rationalisierung, die Reduktion kognitiver Dissonanzen [vgl. Festinger, 1957] oder den sogenannten Hindsight-Bias [vgl. Döring, 2023] zu unterbinden. Die Probanden müssen ihre Bewertung des Systems abgeben, während möglicher emotionaler und kognitiver Stress der moralischen Entscheidung noch unmittelbar nachwirkt.

4.2.6 Debriefing und Abschluss

Nach Abschluss der post-experimentellen Erhebung erfolgt ein standardisiertes Debriefing. Den Probanden wird dabei transparent erklärt, dass das Szenario vollständig fiktiv war und dass es sich bei „Aida“ bzw. „A.I.D.A.“ nicht um eine autonom entscheidende KI, sondern um einen geskripteten Simulated Agent handelt. Zudem wird offengelegt, dass der eigentliche Untersuchungsfokus auf dem Einfluss der Darstellungsform des KI-Agenten auf Vertrauen, Compliance und soziale Adhärenz liegt.

Das Debriefing dient dazu, die im Experiment notwendige teilweise Zurückhaltung des konkreten Untersuchungszwecks nachträglich aufzulösen und mögliche Irritationen durch das moralisch sensible Szenario abzufangen [vgl. Döring, 2023; Baur & Blasius, 2019]. Zusätzlich wird darauf hingewiesen, dass die erhobenen Daten pseudonymisiert verarbeitet werden.

4.3 Operationalisierung und Messinstrumente (Messung H2)

Dieses Kapitel überführt die in den Hypothesen theoretisch aufgebauten Konstrukte in empirisch messbare und quantifizierbare Variablen. Um die statistische Auswertbarkeit zu maximieren, werden standardisierte Metriken und eindeutige binäre Codierungen angewandt.

4.3.1 Messung des Systemvertrauens – adaptiertes Multi-Dimensional Measure of Trust v2

Die Erfassung des Vertrauens (H2a, H2b) erfolgt auf Basis des Multi-Dimensional Measure of Trust v2 nach Malle und Ullman [vgl. Malle & Ullman, 2023; Malle & Ullman, 2025]. Das Instrument eignet sich für das Experiment, da es Vertrauen nicht eindimensional erfasst, sondern zwischen leistungsbezogenem und moralisch-sozialem Vertrauen unterscheidet.

Für das Experiment wird das MDMT v2 in adaptierter Form eingesetzt. Während das originäre Instrument eine Bewertungsskala von 0 bis 7 vorsieht, wird hier eine 7-stufige Likert-Skala verwendet (1 = „trifft gar nicht zu“ bis 7 = „trifft vollkommen zu“). Dadurch entsteht mit dem Wert 4 ein echter neutraler Mittelpunkt. Dies vermeidet bei ambivalenten oder unsicheren Einschätzungen einen Forced-Choice-Effekt und wahrt zugleich die methodische Konsistenz zu den übrigen Kontroll- und Einstellungselementen des Fragebogens [vgl. Porst, 2014].

Die inhaltliche Struktur des MDMT v2 bleibt dabei erhalten. Performance Trust wird als Mittelwert der Subdimensionen Competent (Kompetenz) und Reliable (Verlässlichkeit) berechnet. Moral Trust wird als Mittelwert der Subdimensionen Ethical (ethische Prinzipientreue), Sincere (Aufrichtigkeit) und Benevolent (Wohll wollen) berechnet. Die interne Konsistenz der adaptierten Skalen wird im Rahmen der Auswertung mittels Reliabilitätskennwerten geprüft.

Moral Trust (H2a): Mittelwert aus Ethical, Sincere und Benevolent.

Performance Trust (H2b): Mittelwert aus Competent und Reliable.

4.3.2 Verhaltens-Compliance und soziale Adhärenz

Die Verhaltensvariablen werden als binäre Werte erhoben, um eindeutige Häufigkeitsverteilungen zu generieren:

Verhaltens-Compliance (H1): Wird durch die finale Entscheidung in der Notfall-Architektur (Phase 3) operationalisiert. Die endgültige Bestätigung der utilitaristischen Systemempfehlung (Abschottung) wird als „compliant“ (Wert: 1) codiert, der Abbruch durch den manuellen Override als „non-compliant“ (Wert: 0).

Soziale Adhärenz (H3): Wird durch die initial gewählte Quick-Reply-Antwort in der Routinephase (Phase 1) gemessen. Die Wahl der sozial-höflichen Begrüßung wird mit dem Wert 1 codiert, die rein funktional-direktive Eingabe mit dem Wert 0.

4.3.3 Kontrollvariablen

Um sicherzustellen, dass die gemessenen Effekte (Systemvertrauen und Compliance) kausal auf die experimentelle Manipulation des Interfaces zurückzuführen sind, werden potenzielle Störfaktoren als Kontrollvariablen erhoben. Dazu zählen einerseits soziodemografische Parameter (Alter, Geschlecht, höchster Bildungsabschluss, etc.) und andererseits die allgemeine Technikaffinität sowie die spezifische Vorerfahrung im Umgang mit KI-Systemen [vgl. Lee & See, 2004]. Die Erhebung dieser einstellungsbezogenen Kovariaten erfolgt ebenfalls über 7-stufige Likert-Skalen [vgl. Döring, 2023], um eine methodische Skalenkonsistenz zum MDMT-Instrument zu wahren und den kognitiven Wechsellaufwand für die Probanden gering zu halten. In der statistischen Auswertung dienen diese Daten dazu, die strukturelle Homogenität der randomisierten Versuchsgruppen zu validieren und systematische Verzerrungen durch unterschiedliche Vorerfahrungen auszuschließen.

4.4 Technische Realisierung und Systemarchitektur

Die technische Umsetzung des „Code Black“-Prototyps erfolgt als browserbasierte Single-Page-Application (SPA) unter Verwendung des Frameworks React. Um die strikte methodische Standardisierung des experimentellen Ablaufs zu gewährleisten, wird der KI-Agent nicht durch ein generatives Sprachmodell (Large Language Model) angetrieben. Stattdessen wird das System als deterministischer „Simulated Agent“ über eine Finite-State-Machine („Zustandsautomat“) realisiert.

Diese Architektur stellt sicher, dass sämtliche Systemausgaben, künstlichen Latenzen (beispielsweise durch simulierte Typing-Indicators – siehe 4.1.3) und Interface-Wechsel bei jedem Probanden über alle Endgeräte hinweg möglichst identisch ablaufen. Die State-Machine verwaltet den linearen Progressionsfluss des Experiments durch fest definierte Phasen (Onboarding, Routine, Störfall, Dilemma) und schließt durch starre Übergangsregeln (State Transitions) jegliche unkontrollierbare Varianz im Systemverhalten aus. Diese technische Restriktion garantiert die interne Validität der Simulation, da das erlebte Systemverhalten eine konstante Kontrollvariable bildet.

Zur persistierenden und sicheren Erfassung der quantitativen Messdaten ist das React-Frontend an eine serverseitige Datenbankarchitektur (PostgreSQL) angebunden. Sämtliche kritischen Interaktionsdaten – insbesondere die binären Entscheidungen (Compliance-Messung) sowie die Rohdaten der post-experimentellen Erhebung – werden über asynchrone API-Aufrufe pseudonymisiert übertragen. Jeder Datensatz wird mit einem eindeutigen Session-Identifizier und serverseitigen Zeitstempeln (Timestamps) geloggt. Dies sichert einerseits die Datenintegrität bei potenziellen clientseitigen Verbindungsabbrüchen ab und ermöglicht andererseits einen standardisierten Export der Rohdaten für die inferenzstatistische Analyse.

4.5 Stichprobe und Datenerhebung

Die Erhebung der quantitativen Daten erfolgt über ein asynchrones Online-Verfahren (Web-Based-Experiment). Als Sampling-Strategie wird ein Convenience-Sampling (Gelegenheitsstichprobe) angewandt [Quelle Döring 2023]. Die Rekrutierung der Probanden findet primär über digitale Kanäle statt, wobei insbesondere studentische Netzwerke, das berufliche Umfeld sowie private und familiäre Verteiler genutzt werden.

Zur Absicherung der statistischen Teststärke für die geplanten Mittelwertvergleiche und Häufigkeitsanalysen wird eine Mindeststichprobengröße von $N = 100$ anvisiert. Die Orientierung an dieser Zielgröße wird im weiteren Verlauf durch eine a-priori- bzw. Sensitivitätsanalyse mit G*Power überprüft [vgl. Faul et al., 2009].

Die Zuweisung der Teilnehmenden in die Experimental- („Aida“) oder Kontrollgruppe („A.I.D.A.“) erfolgt deterministisch und verdeckt unmittelbar beim initialen Aufruf der Applikation durch eine serverseitige pseudo Randomisierung.

Einschlusskriterien für die Teilnahme sind ein Mindestalter von 18 Jahren sowie ausreichende Deutschkenntnisse, um der narrativen Einführung und den Systemdirektiven kognitiv und zeitgerecht folgen zu können. Spezifische IT- oder Gaming-Vorkenntnisse sind für die Teilnahme explizit nicht erforderlich, da diese Faktoren separat als Kontrollvariablen (vgl. Kapitel 4.3.3) erfasst und statistisch kontrolliert werden.

4.6 Geplante statistische Auswertung

Die statistische Auswertung orientiert sich an den drei Hypothesen der Arbeit. Da Compliance und soziale Adhärenz jeweils als Ja/Nein-Entscheidung erhoben werden, werden hier die Häufigkeiten zwischen Avatar- und Terminal-Gruppe verglichen. Dafür wird ein Chi-Quadrat-Test verwendet. Sollten einzelne Antwortkategorien zu gering besetzt sein, wird stattdessen der exakte Test nach Fisher herangezogen. Zusätzlich wird die Odds Ratio angegeben, um die Stärke eines möglichen Unterschieds besser einschätzen zu können [vgl. Döring, 2023; Agresti, 2007].

Für die Auswertung des Systemvertrauens werden die jeweiligen MDMT-v2-Skalen als Mittelwerte berechnet. Vor der eigentlichen Hypothesenprüfung wird geprüft, ob die verwendeten Skalen ausreichend zuverlässig sind. Dafür werden Reliabilitätskennwerte wie Cronbachs Alpha oder, falls passend, McDonald's Omega berechnet [vgl. Cronbach, 1951; Dunn et al., 2014].

Die Gruppenunterschiede beim Moral Trust und Performance Trust werden anschließend mit einem t-Test für unabhängige Stichproben geprüft. Falls die Daten die Voraussetzungen dafür deutlich nicht erfüllen, wird alternativ ein Mann-Whitney-U-Test verwendet. Zusätzlich wird Cohen's d als Effektgröße berichtet, damit nicht nur die statistische Signifikanz, sondern auch die praktische Größe eines möglichen Unterschieds sichtbar wird [vgl. Field, 2018; Cohen, 1988].

Bei H2b wird erwartet, dass sich der Performance Trust zwischen den beiden Gruppen nicht wesentlich unterscheidet. Ein nicht-signifikantes Ergebnis wird dabei nicht automatisch als Beweis für Gleichheit gewertet. Falls die finale Stichprobengröße dies sinnvoll zulässt, kann ergänzend ein Äquivalenztest durchgeführt werden, um zu prüfen, ob ein möglicher Unterschied praktisch vernachlässigbar ist [vgl. Lakens, 2018].

Die Kontrollvariablen werden zunächst deskriptiv ausgewertet, um zu prüfen, ob sich die beiden Gruppen trotz Randomisierung auffällig voneinander unterscheiden. Falls sich hier relevante Unterschiede zeigen, können diese Variablen ergänzend in die Auswertung aufgenommen werden [vgl. Döring, 2023].

Verwendete Quellen für Methodik-Kapitel (Entwurfs-Übersicht)

- Agresti, A. (2007). *An Introduction to Categorical Data Analysis* (2nd ed.). Wiley.
- Aronson, E., & Carlsmith, J. M. (1968). *Experimentation in social psychology*.
- Bartneck, C., Kulić, D., Croft, E., & Zoghbi, S. (2009). Measurement instruments for the anthropomorphism, animacy, likeability, perceived intelligence, and perceived safety of robots.
- Baur, N., & Blasius, J. (Hrsg.). (2019). *Handbuch Methoden der empirischen Sozialforschung*. Springer VS.
- Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences* (2nd ed.). Lawrence Erlbaum.
- Costa, A., Foucart, A., Hayakawa, S., Aparici, M., Apesteguia, J., Heafner, J., & Keysar, B. (2014). Your Morals Depend on Language.
- Cronbach, L. J. (1951). Coefficient alpha and the internal structure of tests.
- Döring, N. (2023). *Forschungsmethoden und Evaluation in den Sozial- und Humanwissenschaften*. Springer.
- Dunn, T. J., Baguley, T., & Brunsden, V. (2014). From alpha to omega: A practical solution to the pervasive problem of internal consistency estimation.
- Elish, M. C. (2019). *Moral Crumple Zones: Cautionary Tales in Human-Robot Interaction*.
- Epley, N., Waytz, A., & Cacioppo, J. T. (2007). On seeing human: A three-factor theory of anthropomorphism.
- Faul, F., Erdfelder, E., Buchner, A., & Lang, A.-G. (2009). Statistical power analyses using G*Power 3.1: Tests for correlation and regression analyses.
- Festinger, L. (1957). *A Theory of Cognitive Dissonance*.
- Field, A. (2018). *Discovering Statistics Using IBM SPSS Statistics* (5th ed.). SAGE.
- Gnambs, T., & Kaspar, K. (2015). Disclosure of sensitive behaviors across self-administered survey modes: A meta-analysis.
- Gnewuch, U., Morana, S., Heckmann, C., & Maedche, A. (2018). Faster Is Not Always Better: Understanding the Effect of Dynamic Response Delays in Human-Chatbot Interaction.
- Greene, J. D., Morelli, S. A., Lowenberg, K., Nystrom, L. E., & Cohen, J. D. (2008). Cognitive load selectively interferes with utilitarian moral judgment.
- Hadjichristidis, C., Geipel, J., & Surian, L. (2017). Foreign language effects on moral dilemma judgments.
- Highhouse, S. (2009). *Designing Experiments That Generalize*.
- Kahneman, D. (2011). *Thinking, Fast and Slow*.
- Lakens, D. (2018). *Equivalence Testing for Psychological Research: A Tutorial*.
- Lee, J. D., & See, K. A. (2004). *Trust in Automation: Designing for Appropriate Reliance*.
- Malle, B. F., & Ullman, D. (2023). *Measuring Human-Robot Trust with the MDMT (Multi-Dimensional Measure of Trust)*.
- McPherson, M. J. (1993). *Subsurface Ventilation Engineering*.
- Mori, M. (1970). *The Uncanny Valley*.
- Nass, C., Steuer, J., & Tauber, E. R. (1994). Computers are social actors.
- Nass, C., & Moon, Y. (2000). *Machines and mindlessness: Social responses to computers*.
- Porst, R. (2014). *Fragebogen: Ein Arbeitsbuch*. Springer VS.
- Reeves, B., & Nass, C. (1996). *The Media Equation*.

- Reips, U.-D. (2000). The Web Experiment Method.
- Siegel, M., Breazeal, C., & Norton, M. I. (2009). Persuasive robotics: The influence of robot gender on human behavior.
- Simmons, J. P., Nelson, L. D., & Simonsohn, U. (2011). False-Positive Psychology: Undisclosed Flexibility in Data Collection and Analysis Allows Presenting Anything as Significant.
- Sindoni, M. G. (2024). The feminization of AI-powered voice assistants: Personification, anthropomorphism and discourse ideologies.
- Ullman, D., & Malle, B. F. (2025). MDMT: Multi-Dimensional Measure of Trust v2.
- UNESCO. (2019). I'd blush if I could: Closing gender divides in digital skills through education.
- Witmer, B. G., & Singer, M. J. (1998). Measuring presence in virtual environments.
- Yoo, Y., Jung, J., Kang, C., Kim, H., & Jun, S. (2024). Do Computers Have Gender Roles?: Investigating Users' Gender Role Stereotyping of Anthropomorphized Voice Agents.

Neue Quellen ggü Disposition (gesicherte PDFs):

- Aronson and Carlsmith 1968 - Some problems with experimentation in social psychology.pdf
- Costa et al 2014 - Your Morals Depend on Language.pdf
- Doering 2023 - Forschungsmethoden.pdf
- Gnequch 2018 - Faster Is Not Always Better Understanding the Effect of Dynamic Response Delays in Human-Chatbot Interaction.pdf
- Greene et al 2008 - Cognitive Load Selectively Interferes with Utilitarian Moral Judgment.pdf
- Reips 2000 - The Web Experiment Method.pdf
- Siegel 2009 - Persuasive robotics The influence of robot gender on human behavior.pdf
- McPhearson 1993 - Subsurface Ventilation Engineering.pdf
- Gnambas Kaspar 2015 - Disclosure of sensitive behaviors across self-administered survey modes a meta-analysis.pdf
- Porst 2014 - Fragebogen - Ein Arbeitsbuch.pdf
- Faul et al 2009 - Statistical power analyses using GPower 3.1 Tests for correlation and regression analyses.pdf
- Bartneck Croft Kulic 2008 - Measuring the anthropomorphism, animacy, likeability, perceived intelligence, and perceived safety of robots.pdf
- Simmons et al 2011 - False-Positive Psychology Undisclosed Flexibility in Data Collection and Analysis Allows Presenting Anything as Significant.pdf
- Highhouse 2009 - Designing Experiments That Generalize.pdf
- Baur Blasius 2019 - Handbuch Methoden der empirischen Sozialforschung.pdf
- Kahneman 2011 - Thinking Fast and Slow.pdf
- UNESCO 2019 - I'd blush if I could closing gender divides in digital skills through education.pdf
- Yoo. et al 2024 - Do Computers Have Gender Roles - Investigating Users Gender Role Stereotyping of Anthropomorphized Voice Agents.pdf
- Sindoni 2024 -The Feminization of AI-Powered Voice Assistants - Personification, Anthropomorphism and Discourse Ideologies.pdf
- Ullmann Malle 2025 - MDMT v2.pdf
- Field 2018 - Discovering Statistics Using IBM SPSS Statistics - 5th.pdf
- Cronbach 1951 - Coefficient alpha and the internal structure of tests.pdf
- Dunn Baguley Brunsden -2014 - From alpha to omega A practical solution to the pervasive problem of internal consistency estimation.pdf
- Agresti 2007 - An Introduction to Categorical Data Analysis 2nd.pdf (Anm. 3rd war nicht ohne weiteres auftreibbar)
- Cohen 1988 - Statistical Power Analysis for the Behavioral Sciences 2nd.pdf
- Lakens (2018 - Equivalence Testing for Psychological Research A Tutorial.pdf